Diagnóstico de fallas en rodamientos con pocos datos de falla y cambio de carga

CNN, Audio Spectrogram Transformer y aumento por difusión condicional

Grupo 6

Hipólito Eusebio Coaguila Berrios · Lenin Dixon Herrera Padilla · Jhafet Martín Cánepa Maceda

6 de noviembre de 2026

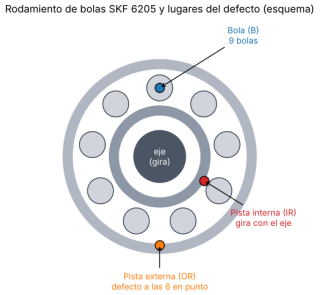
MIA-203 Redes Neuronales y Aprendizaje Profundo · Maestría en Inteligencia Artificial · FIIS – UNI

Docente: Aldo Camargo Fernández-Baca, Ph.D.

¿Por qué importa?

- Los rodamientos causan el **41–44 %** de las fallas de los motores eléctricos (encuestas IEEE y EPRI).
- Una falla sin aviso detiene la máquina y la línea de producción.
- Mantenimiento predictivo: un acelerómetro barato y un modelo que avisa *antes* de la parada.

En el Perú: molinos, fajas y bombas de la minería; bombas de riego y cámaras de frío de la agroindustria; bombeo de agua.



Rodamiento SKF 6205 y lugares del defecto

Formulación del problema

Entrada y salida

Entrada: ventana de vibración $x \in \mathbb{R}^{2048}$ (171 ms a 12 kHz)

Salida: una de **10** clases: Normal o falla en bola / pista interna / pista externa, con 3 severidades

Éxito

F1-macro en una carga del motor nunca vista (3 HP), recall de las fallas escasas y robustez al ruido.

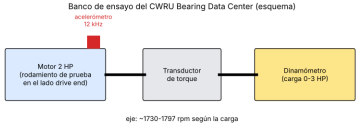
Dos dificultades reales de planta

1. **Pocos datos de falla**: las graves son rarísimas
   $\Rightarrow$ desbalance inducido 30 % / 10 % / **3 %**
2. **Cambio de condición**: la máquina opera con cargas no vistas
   $\Rightarrow$ entrenar 0–2 HP, probar 3 HP

Trabajos relacionados

Tema	Qué hacen	Nuestra diferencia
Diagnóstico clásico y CWRU Randall y Antoni 2011; Smith y Randall 2015	Envolvente en BPFO/BPFI; CWRU tiene condiciones difíciles	Usamos la física para *verificar* a la red
Revisiones DL en CWRU Neupane y Seok 2020; Zhao et al. 2020	Exactitudes $\approx$100 %, a menudo con fuga	Partición por carga y en el tiempo
CNN 1D: WDCNN Zhang et al. 2017	CNN sobre la señal cruda	Nuestra línea base
Transformer, ViT, AST Vaswani 2017; Gong 2021	Atención sobre parches del espectrograma	¿Se transfiere el audio a vibración?
Difusión para desbalance Ho 2020; Yang 2024; Wang 2024	Imágenes tiempo-frecuencia, misma condición	Señal 1D, carga no vista, control de sobremuestreo

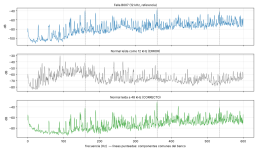
Datos: CWRU Bearing Data Center



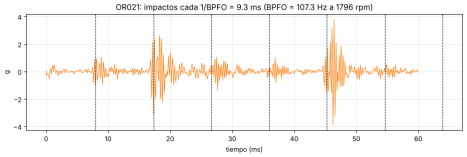
- Motor de 2 HP, acelerómetro *drive end*, 12 kHz
- 4 cargas (0–3 HP, 1797–1730 rpm)
- **40** archivos = 10 clases × 4 cargas, ∼10 s c/u

Dos errores del conjunto, corregidos

1. La clase **Normal está a 48 kHz**, no a 12 kHz: sin corregir, la red podía reconocerla por la escala espectral (atajo).
2. `99_Normal_2.mat` traía una **copia de la carga 1**.



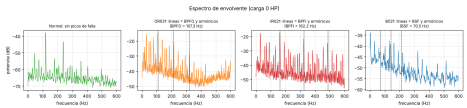
La física de la falla



Cada vez que una bola pasa por el defecto hay un **impacto**. El ritmo depende de dónde está el daño:

$$\mathrm{BPFO} = \frac{N_b}{2} f_r \left(1 - \frac{d}{D}\cos\phi\right) = 3{,}585\, f_r$$

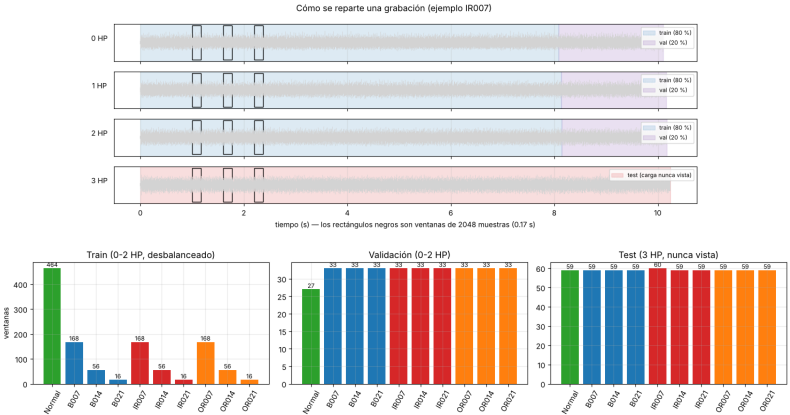
$$\mathrm{BPFI} = \frac{N_b}{2} f_r \left(1 + \frac{d}{D}\cos\phi\right) = 5{,}415\, f_r$$



Espectro de envolvente: picos en BPFO / BPFI y armónicos. La bola es la más difícil (pico débil).

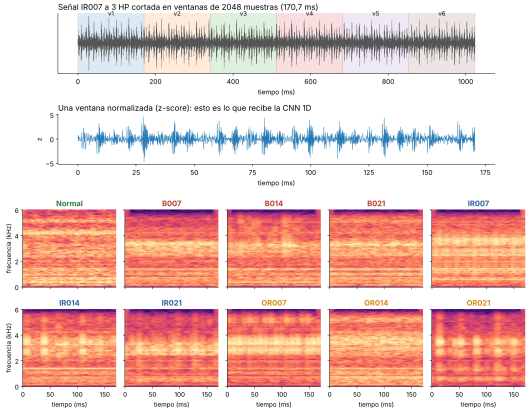
A 3 HP: BPFO $\approx$ 103 Hz, BPFI $\approx$ 156 Hz.

Partición sin fuga y desbalance



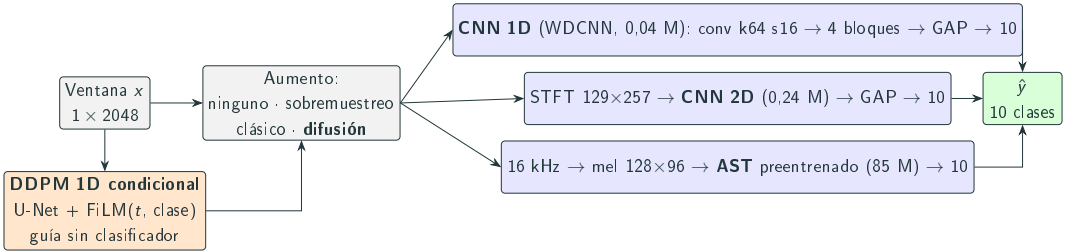
Train: 1184 ventanas (0–2 HP, 80 % inicial) · Val: 324 (20 % final, sin solape) · Test: 591 (3 HP completa, nunca vista)

De la señal a la entrada de cada red



Arriba: ventanas para la CNN 1D. Abajo: log-STFT de una ventana por clase (entrada de la CNN 2D); los impactos son bandas verticales en 2–4 kHz.

Arquitectura propuesta



CNN 1D vs CNN 2D: efecto de la representación (señal vs espectrograma).
CNN 2D vs AST: efecto del Transformer con preentrenamiento.

AST: remuestreo a 16 kHz (frecuencia de preentrenamiento) y espectrograma en fp32 (evita desbordamiento en fp16).

Formulación y función de pérdida

Clasificadores (entropía cruzada):

$$\mathcal{L}(\theta) = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C} y_{i,c}\log p_\theta(c \mid x_i)$$

DDPM (predice el ruido):

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}\left\|\epsilon - \epsilon_\theta\left(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon,\ t,\ y\right)\right\|^2$$

Guía sin clasificador ($w = 2$):

$$\tilde{\epsilon} = (1+w)\,\epsilon_\theta(x_t, t, y) - w\,\epsilon_\theta(x_t, t, \varnothing)$$

Cuatro estrategias de aumento

- **Ninguno**: train desbalanceado
- **Sobremuestreo** (control): repetir ventanas reales hasta igualar clases
- **Clásico**: ruido 10–30 dB, desplazamiento, escala, SpecAugment
- **Difusión**: 3456 ventanas sintéticas (mismo número que el sobremuestreo)

Pregunta clave

¿La difusión aporta *más* que solo equilibrar las clases?

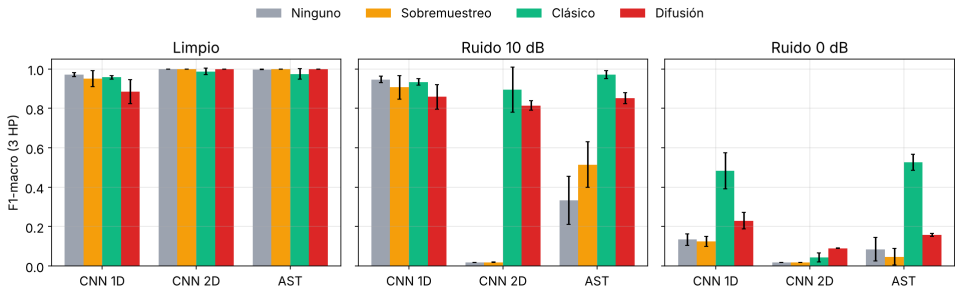
Entrenamiento y métricas

Optimizador	AdamW, decaimiento 0,01
Schedule	calentamiento 5 % + coseno
CNN 1D / 2D	30 épocas, tasa 10^{-3}
AST	8 épocas, tasa 3×10^{-5}
DDPM	60 épocas, $T = 1000$, 50 pasos DDIM
Parada	mejor F1-macro en validación
Semillas	0, 1, 2
Corridas	$3 \times 4 \times 3 = \mathbf{36}$
Hardware	Google Colab, GPU Tesla T4

Métricas

- **F1-macro** en 3 HP: pondera igual a cada clase (la exactitud premiaría a Normal)
- Recall por clase (clases escasas)
- F1-macro con ruido blanco a **10 dB** y **0 dB**
- Media $\pm$ desviación sobre 3 semillas

Resultados: señal limpia y con ruido



Limpio: CNN 2D y AST llegan a **1,000**; la línea base, a **0,972**. El cambio de carga queda casi resuelto.

10 dB: sin aumento, la CNN 2D colapsa (0,018) y el AST cae a 0,333.

0 dB: solo el aumento **clásico** resiste (AST 0,527; CNN 1D 0,484).

Ablación: ¿difusión o solo equilibrar clases?

F1 a 10 dB	Ninguno	Sobremuestreo	**Difusión**
CNN 2D	0,018	0,019	**0,815**
AST	0,333	0,514	**0,851**

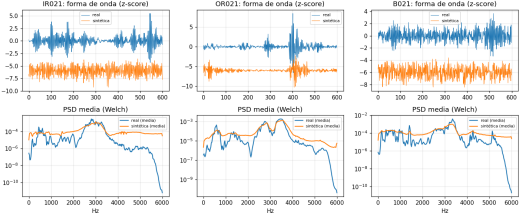
Mismo número de ventanas por clase en sobremuestreo y difusión.

Conclusión

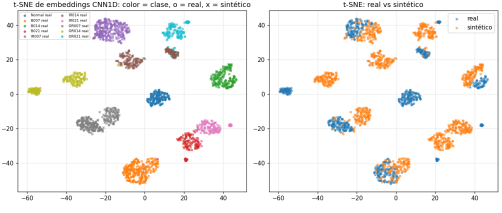
La mejora viene del **contenido** de las muestras generadas, no del equilibrio de clases.

Explicación plausible: las sintéticas conservan un piso de ruido de banda ancha que actúa como aumento de ruido implícito.

Calidad de las muestras sintéticas



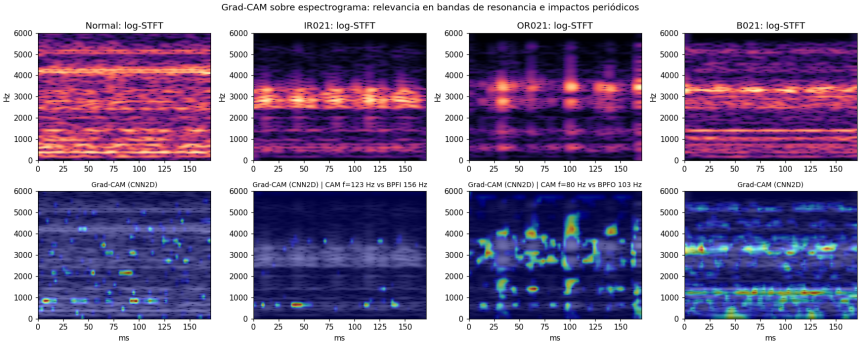
Reproducen los impactos y la resonancia de 2,5–3,5 kHz; queda ruido en altas frecuencias.



TSTR (entrenar solo con sintéticas): F1 = **0,680 ± 0,071**.

Pico físico de envolvente correcto: 98–100 % en IR007/OR007, 16–20 % en IR014/IR021.

¿Qué mira la red? Grad-CAM



Centroide del Grad-CAM entre **2,0 y 3,7 kHz**: la **banda de resonancia** que excitan los impactos.

Pero la periodicidad del mapa coincide con BPFO/BPFI solo en 0–30 % (la envolvente cruda: 97–100 %).

Discusión: limitaciones, sesgos y uso responsable

Limitaciones

- Cada falla de CWRU es **un solo rodamiento** en 4 cargas: se generaliza a una carga nueva, no a un rodamiento nuevo.
- Daños artificiales (electroerosión), no desgaste real.
- Normal: una sola grabación por carga.
- El AST se preentrenó con audio, no con vibración.

Uso responsable e impacto

- Validar en cada máquina antes de usar: riesgo de falsas alarmas o fallas no detectadas.
- Apoyo al técnico (verificar con la envolvente), no parada automática.
- Las sintéticas no reemplazan datos reales de validación.
- Útil para pymes peruanas con pocos registros de falla.

Conclusiones y trabajo futuro

1. Con particiones sin fuga, la dificultad real de CWRU **no es el cambio de carga** (F1 = 1,000) sino el ruido y el desbalance en modelos pequeños.
2. La difusión aporta **robustez al ruido** que no se explica por el equilibrio de clases (AST: 0,333 $\rightarrow$ 0,851 a 10 dB).
3. El aumento clásico sigue siendo la mejor defensa ante ruido severo (0 dB).
4. Los modelos aprenden la **firma espectral de la resonancia**, no la periodicidad física de los impactos.

Trabajo futuro: validar en Paderborn y en equipos peruanos · filtrar sintéticas con criterios físicos (BPFO/BPFI) · CNN 1D en microcontrolador · vida útil remanente con PINNs.

¡Gracias!

¿Preguntas?



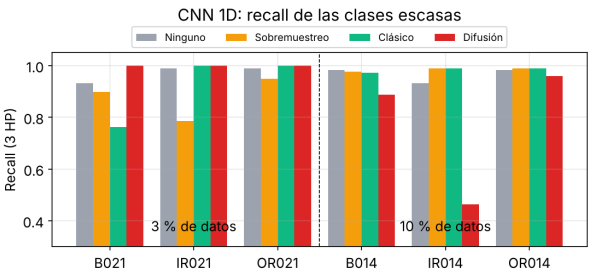
github.com/jafcn09/examenfinal_redes_uniingenieria

Respaldo: Contribuciones

1. **Curación de datos exigente** sobre CWRU: partición por carga sin fuga, desbalance de cola larga, evaluación con ruido y corrección de dos errores del conjunto (muestreo de la clase Normal y archivo duplicado).
2. **Combinación de arquitecturas**: un único DDPM condicional 1D genera ventanas de las clases escasas para tres clasificadores (CNN 1D, CNN 2D, AST).
3. **Evaluación controlada** 3×4 **con 3 semillas**: el control de sobremuestreo separa el efecto de equilibrar clases del aporte del generador; interpretabilidad contrastada con la física (BPFO/BPFI).

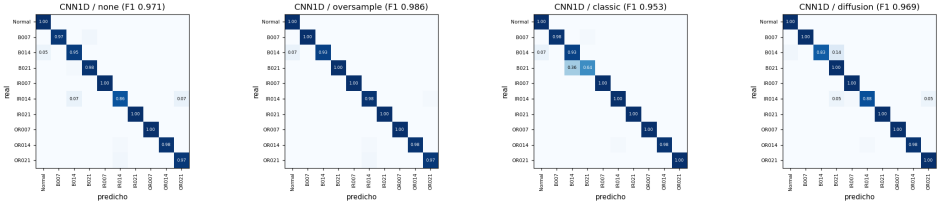
Toca tres unidades del curso: **CNN** · **Transformers** · **modelos de difusión**

Respaldo: Clases escasas: efecto mixto en la CNN 1D



- Clases con 3 %: recall **0,970** → **1,000** con difusión.
- Pero IR014 cae a 0,463 ⇒ F1 0,885 ± 0,060.
- Sobremuestreo: repetir 16 ventanas **sobreajusta** (0,878).
- CNN 2D y AST: >0,99 de recall en todas las estrategias.

Respaldo: Análisis de errores



- En limpio, los errores se concentran en la **bola** (B014 vs B021) e IR014: las condiciones más difíciles según la envolvente.
- Con ruido, los modelos sin aumento predicen todo como Normal: el ruido de banda ancha se parece al espectro plano del rodamiento sano.
- La atención del AST es casi uniforme, con un leve máximo en 3,3 kHz para las fallas.

Respaldo: Costo computacional

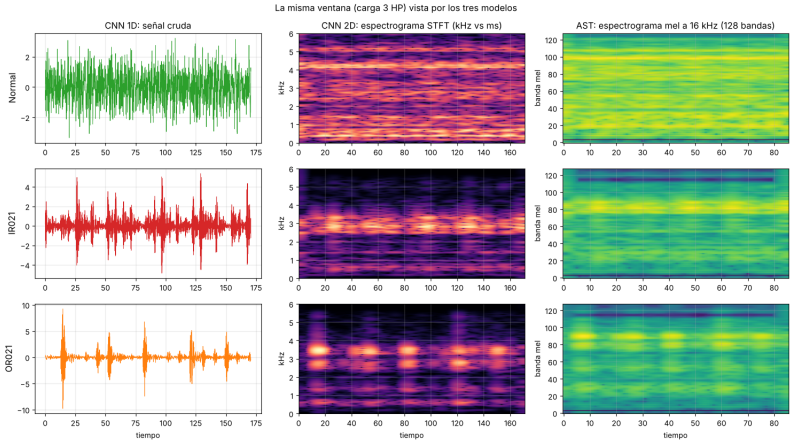
Modelo	Parámetros	ms/ventana (CPU)
CNN 1D	**0,04 M**	**0,03**
CNN 2D	0,24 M	15,8
AST	85 M	86,1

- Todos los experimentos: **0,95 h** de GPU (Tesla T4).
- Las 12 corridas del AST: 63 % del tiempo.
- La CNN 1D tiene $\sim$**2000 veces menos parámetros** que el AST $\Rightarrow$ candidata para un microcontrolador junto a la máquina.

Respaldo: resultados completos (3 HP, 3 semillas)

Modelo	Aumento	F1-macro	F1 (10 dB)	F1 (0 dB)	Exactitud
CNN 1D	Ninguno	0,972 ± 0,010	0,947 ± 0,016	0,134 ± 0,028	0,972 ± 0,010
CNN 1D	Sobremuestreo	0,952 ± 0,041	0,907 ± 0,061	0,125 ± 0,025	0,954 ± 0,037
CNN 1D	Clásico	0,958 ± 0,009	0,934 ± 0,016	0,484 ± 0,091	0,959 ± 0,009
CNN 1D	Difusión	0,885 ± 0,060	0,859 ± 0,062	0,230 ± 0,043	0,896 ± 0,052
CNN 2D	Ninguno	1,000 ± 0,000	0,018 ± 0,000	0,018 ± 0,000	1,000 ± 0,000
CNN 2D	Sobremuestreo	1,000 ± 0,000	0,019 ± 0,001	0,018 ± 0,000	1,000 ± 0,000
CNN 2D	Clásico	0,988 ± 0,017	0,895 ± 0,115	0,044 ± 0,024	0,988 ± 0,017
CNN 2D	Difusión	1,000 ± 0,000	0,815 ± 0,024	0,090 ± 0,002	1,000 ± 0,000
AST	Ninguno	0,997 ± 0,002	0,333 ± 0,122	0,086 ± 0,059	0,997 ± 0,002
AST	Sobremuestreo	1,000 ± 0,000	0,514 ± 0,115	0,047 ± 0,041	1,000 ± 0,000
AST	Clásico	0,975 ± 0,027	0,971 ± 0,020	0,527 ± 0,040	0,977 ± 0,025
AST	Difusión	0,999 ± 0,001	0,851 ± 0,028	0,158 ± 0,007	0,999 ± 0,001

Respaldo: lo que “ve” cada modelo



En las fallas se ven franjas periódicas: los impactos repetidos a BPFI / BPFO.

Respaldo: curva del DDPM y Grad-CAM 1D

